


Data Mining

(Introduzione al Machine Learning)

Gianluca Rossi
gianluca.rossi@uniroma2.eu

Problema

la sequenza di
punti forma un
quadrato?



Soluzione tradizionale

Dalla definizione di quadrato, trovare una serie di regole che sono vere se e solo se i punti formano un quadrato.

Definizione di quadrato: un poligono con quattro lati, i cui lati sono tutti congruenti e i cui angoli interni sono tutti retti.

- **INPUT:** Una sequenza di punti P
- Se formano un quadrato, i vertici sono dati dai minimi e massimi delle coordinate ovvero:
 $(\text{min_x}, \text{min_y}), (\text{max_x}, \text{min_y}), (\text{min_x}, \text{max_y}), (\text{max_x}, \text{max_y})$
- Algoritmo
 1. Per ogni punto, la ascissa deve essere uguale a min_x o max_x ; l'ordinata a min_y o max_y (*ogni punto appartiene al perimetro*)
 2. I vertici sono in P (*gli angoli interni sono retti*)
 3. $\text{max_x} - \text{min_x}$ è uguale a $\text{max_y} - \text{min_y}$ (*lati congruenti*)

```
def is_square(points):
    max_x = max([x for x, y in points])
    min_x = min([x for x, y in points])
    max_y = max([y for x, y in points])
    min_y = min([y for x, y in points])

    for x,y in points:
        if not x in (min_x, max_x) and not y in (min_y, max_y):
            return False

    if not (min_x,min_y) in points or not (min_x,max_y) in points \
        or not (max_x,min_y) in points or not (max_x,max_y) in points:
        return False

    if max_x - min_x != max_y - min_y:
        return False

    return True
```


E questa sequenza?

Secondo la nostra definizione NO!

SI in alcuni contesti applicativi
(riconoscimento di immagini)

NO controllo della qualità di un
prodotto industriale

Senza regola 2 lo sarebbe ma ...






... lo sarebbe anche questa

NO eliminare regole

SI definizione soglie di tolleranza
complicando l'algoritmo

Oppure usare un altro approccio...



Machine Learning

Apprendere da esempi, senza bisogno di regole precise

Esempi SI



Esempi NO



01

GLI ESEMPI SONO
ETICHETTATI

02

ESTRAENDO
INFORMAZIONI DAGLI
ESEMPI SI CERCANO
SCHEMI E REGOLE CHE
DISTINGUONO QUADRATI
DA NON QUADRATI

03

SI OTTIENE UN MODELLO
CHE È IN GRADO DI
CLASSIFICARE NUOVI
ESEMPI




	points	target
0	22.129033863115254,47.34883033120149,18.032419...	0
1	-17.480015366308734,50.65032922584781,-22.6183...	1
2	-35.92600996967168,50.745005480052164,-45.6815...	1
3	45.23127400498937,50.62026697965084,43.4617997...	1
4	-49.95117670955973,-8.909670479709467,-50.4802...	1
...	...	...
195	-48.389677620844594,23.702038993170945,-45.277...	0
196	-21.10061917721292,-48.85527629016038,-12.0984...	1
197	-31.326309920354134,-40.15378460793167,-20.245...	0
198	-48.536757396275064,23.386943105928626,-50.836...	0
199	-49.620714635936274,-32.40030910612848,-24.074...	0




Quali info estrarre? Dipende dal problema


Servono delle caratteristiche – **features** - che distinguono il quadrato dal resto

Bassa varianza tra le distanze dal centroide




Bassa varianza tra le distanze dal bounding box





MODELLO
 $y=ax+b$



Le Fasi del Machine Learning

Dal Dato al Modello

Raccolta e Analisi dei Dati

- Dai dati grezzi a *feature* utilizzabili

Scelta del modello

- Analisi preliminare dei dati → modello

Addestramento del modello

- Ricerca di parametri ottimali del modello


Valutazione del modello

Limiti

Il modello predice bene rispetto ai dati disponibili →
predice bene qualunque dato futuro



Le features descrivono adeguatamente tutte le
informazioni utili alla predizione?



È vero che errori molto gravi sono estremamente
rari?



È vero che la correttezza di un risultato non
dipende dal valore di una etichetta?



Compiti principale nel machine learning

- **CLASSIFICAZIONE**

- Obiettivo: **assegnare un'etichetta** a un nuovo dato
- Le etichette provengono da un **insieme finito e noto**
- Funziona tramite un **modello addestrato su dati già etichettati**
- Ovvero applica una funzione

$f: X$ (features di un dato) $\rightarrow Y$ (insieme finito di etichette)

Compiti principale nel machine learning

- **REGRESSIONE**

- Obiettivo: **predice un valore numerico continuo**
- Sono noti già noti (x_i, y_i) con $y_i \in \mathbb{R}$
- Si vuole predire il valore per un nuovo x
- Ovvero applica una funzione

$$f: X \rightarrow \mathbb{R}$$




Compiti principale nel machine learning

- **CLUSTERING**
 - Obiettivo: **trovare strutture o somiglianze**
 - **Nessun dato etichettato a priori**
 - Numero di dati potrebbe essere noto o stimato dall'algoritmo
-


Un primo modello

k-Nearest Neighbors (kNN)

- Si assegna la classe più frequente tra quelle dei k vicini più prossimi
- I valori tipici di k sono numeri piccoli 5, 7,...
- Nessun addestramento





Classificazione Iris



	0	1	2	3	4
0	6.8	3.2	5.9	2.3	Iris-virginica
1	4.9	3.1	1.5	0.1	Iris-setosa
2	5.7	2.9	4.2	1.3	Iris-versicolor
3	5.8	2.6	4.0	1.2	Iris-versicolor
4	5.1	3.8	1.5	0.3	Iris-setosa
...	...	...	...	...	...
145	6.0	3.0	4.8	1.8	Iris-virginica
146	5.1	3.4	1.5	0.2	Iris-setosa
147	4.8	3.0	1.4	0.3	Iris-setosa
148	6.1	2.6	5.6	1.4	Iris-virginica
149	5.8	2.7	4.1	1.0	Iris-versicolor

2 features su 4



Implementazione del classificatore

- Sarà una classe che gestirà l'intero processo: dall'apprendimento alla classificazione
- Tre metodi
 - `__init__` inizializza i parametri
 - `fit` che si occupa dell'apprendimento, ovvero della definizione dei parametri
 - `predict` classifica un nuovo dato usando le regole imparate con `fit`

```
class Classificatore:
    def __init__(self #, altri eventuali parametri
                ):
        """
        Inizializza i parametri del classificatore.
        """
        self.a, self.b = None, None
        # altri parametri

    def fit(self, X_train, y_train):
        """
        Esegue l'algoritmo di addestramento usando
        X_train: Matrice delle features
        y_train: Etichette di classe (es. 0 o 1).
        """
        # algoritmo di addestramento

    def predict(self, X_test):
        """
        Ritorna le previsioni su nuovi dati X_test
        """
```